# DATA SCIENTIST | MACHINE LEARNING

**FATIMA ADDA-REZIG**

Yvelines (78) · Île-de-France · Disponible immédiatement · Télétravail accepté

06 59 16 24 81 | adda.fatima@hotmail.fr | GitHub | LinkedIn

## PROFIL

Ingénieure en biochimie forte de 5 ans d'expérience en recherche (laboratoire académique et CRO), formée à la data science. Je relie deux mondes : la connaissance du terrain expérimental (données de laboratoire, exigences qualité, enjeux biologiques) et les compétences pour construire, évaluer et déployer des modèles de machine learning et d'IA générative. Objectif : mettre cette double compétence au service de la santé et de la recherche.

## EXPÉRIENCES PROFESSIONNELLES ET PROJETS DATA SCIENCE

**Data Scientist / Machine Learning** | Projets appliqués en formation · OpenClassrooms | mars - déc. 2026

**Solubilité des protéines — ML & Deep Learning —** Audit DeepSol, contrôle des homologies, comparaison LightGBM/ESM-2, fine-tuning, calibration et aide aux choix expérimentaux ; démonstrateur Gradio en ligne.
**Technologies :** Python, PyTorch, ESM-2, LightGBM, Optuna, MLflow, Gradio, Hugging Face · GitHub

**API RAG / LLM — recherche d'événements —** Ingestion de données ouvertes, indexation FAISS, recherche sémantique, génération Mistral et contrôle de pertinence des sources ; API déployée sur Render.
**Technologies :** Python, FastAPI, LangChain, FAISS, Mistral AI, Render

**Assistant documentaire — OCR & LLM —** Extraction OCR, recherche augmentée par documents et données SQL ; tests de fidélité et de pertinence des réponses.
**Technologies :** Nanonets OCR, Mistral, SQL, FAISS, RAGAS, Streamlit

**Classification d'IRM cérébrales — Deep Learning —** Prototypage sur images partiellement annotées : CNN, transfert d'apprentissage et approche semi-supervisée.
**Technologies :** Python, PyTorch, CNN, OpenCV

**Research Associate in Biology** | NOVALIX · CRO, Romainville | oct. 2024 – janv. 2026

- Expression et purification de protéines recombinantes (E. coli, insectes, cellules de mammifères) ; analyses biophysiques et contrôle qualité (SEC-MALS, NanoDSF, SDS-PAGE, Western blot).
- Structuration, traçabilité des données expérimentales (Labfolder) et restitution scientifique aux équipes et clients R&D.

**Ingénieure d'étude** | I2BC · CNRS / CEA / Université Paris-Saclay | déc. 2017 – fév. 2021

- Recherche en biologie moléculaire et structurale ; purification de protéines, interactions protéines/ADN (SEC, switchSENSE, AUC), cristallographie.
- Optimisation de protocoles reproductibles, analyse des résultats, documentation et communication scientifique.

## FORMATION

**Data Scientist – Machine Learning** | OpenClassrooms · RNCP niveau 7 · 2026 · 13 projets soutenus et validés
**Data Scientist** | DataScientest · 2021 · 400 h : Python, SQL, PySpark, ML, Deep Learning, NLP
**Master 2 Biochimie, Biologie moléculaire et Biotechnologies |** Université d'Orléans · 2017

## COMPÉTENCES TECHNIQUES

**Data Analyse —** Python, pandas, NumPy, SQL / PostgreSQL, exploration, nettoyage et contrôle qualité.
**Data Visualisation —** Matplotlib, Seaborn, tableaux de bord, Streamlit, restitution scientifique.
**Data Science & IA —** scikit-learn, LightGBM, XGBoost, PyTorch, CNN, Optuna, SHAP, LLM, RAG, OCR, LangChain, FAISS, RAGAS.
**Data Drift & MLOps —** Suivi de dérive, MLflow, FastAPI, Docker, Git/GitHub, GitHub Actions, pytest, Hugging Face, Render.