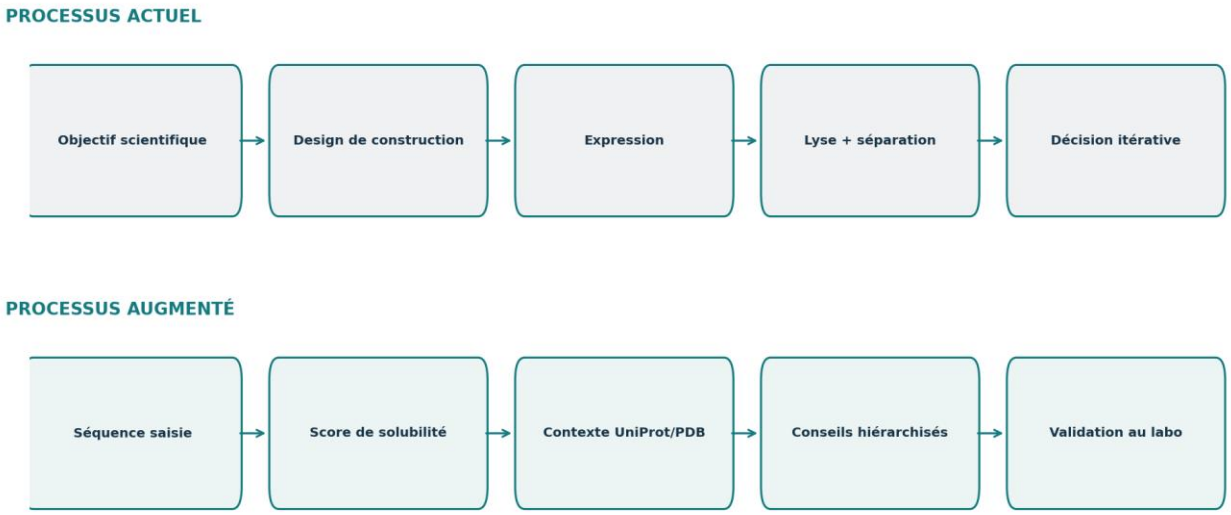
OPENCLASSROOMS / CONDUITE DE PROJET DATA & MACHINE LEARNING

Rapport de conduite de projet Data & ML

Prédire la solubilité des protéines : une aide à la sélection des constructions et aux essais de laboratoire



Fatima ADDA-REZIG

Projet individuel de formation Data Scientist – Machine Learning | Domaine : biotech / production de protéines

État du projet : démonstrateur publié — 25 octobre 2026

Rapport rédigé selon le template de conduite de projet Data & ML fourni pour la formation. Analyse orientée métier, décisions de pilotage et preuves vérifiables. Détail scientifique en annexes.

RÉSUMÉ EXÉCUTIF

Une décision plus éclairée avant le laboratoire

Le problème. En production de protéines, une construction peut sembler pertinente sur le papier, mais produire trop peu de matière soluble pour être étudiée. Les essais ratés mobilisent des cultures, des consommables et du temps scientifique. Aujourd'hui, le choix des constructions repose largement sur l'expérience et sur des cycles de tests successifs.

La proposition. J'ai développé un outil dans lequel le chercheur colle une séquence de protéine. Il obtient une estimation de sa propension à être soluble, une identification biologique lorsque les bases publiques permettent une correspondance fiable, puis une liste argumentée d'essais à comparer : construction simple, étiquette de purification, hôte de production et contrôles fonctionnels.

La réalisation. Après plusieurs versions et comparaisons, le démonstrateur est disponible en ligne, avec des tests automatisés et un code source documenté. Le meilleur modèle testé distingue mieux les protéines solubles et insolubles sur le jeu utilisé pour sa mise au point : son indicateur de discrimination est d'environ **0,83 sur une échelle de 0,5 (hasard) à 1 (parfait)**. Cette mesure ne suffit pas à prouver un gain réel de laboratoire.

La décision. Arrêter les évolutions du prototype, garder une version stable et préparer un pilote biologique indépendant. Le succès du pilote ne sera pas uniquement la qualité de prédiction : il faudra vérifier si l'outil permet de choisir de meilleurs essais, avec un coût et un délai acceptables.

Question du décideur	Réponse actuelle
À quoi cela sert-il ?	Prioriser les constructions à tester, sans remplacer les essais.
Quel résultat existe ?	Démonstrateur fonctionnel ; score de développement ≈ 0,83.
Qu'est-ce qui n'est pas encore établi ?	La réduction effective des essais, du temps et des dépenses.
Quelle est la décision suivante ?	Pilote sur nouvelles constructions avec traçabilité des résultats.

Convention de lecture : résultats mesurés = issus des sorties de test ; estimations = hypothèses économiques ; projet futur = proposition de pilotage. Les valeurs complètes et méthodes sont disponibles en annexes.

MODE DE LECTURE

Des concepts utiles sans jargon

Comprendre en moins de deux minutes

Terme rencontré	Traduction opérationnelle
Modèle prédictif	Programme qui apprend à classer des séquences à partir d'exemples.
Score de 0 à 1	Indication de solubilité : ce n'est pas un rendement de purification.
Seuil de décision	Valeur à partir de laquelle le logiciel dit « soluble ».
Faux positif	Prédit soluble, mais insoluble dans les données : risque d'essai inutile.
Faux négatif	Prédit insoluble, mais soluble dans les données : possibilité écartée.
Qualité de discrimination (AUC)	Capacité du modèle à classer une vraie soluble devant une vraie insoluble.
Calibration	Vérification de la cohérence entre les scores affichés et les fréquences observées.

Trois niveaux de preuve, utilisés dans la suite

- **Mesuré :** données, dates Git, résultats de tests et livrables contrôlés.
- **En développement :** performances utiles pour comparer les options, mais non certifiées sur une nouvelle cohorte.
- **Hypothèse ou cible :** estimation budgétaire, gain attendu ou seuil proposé pour un pilote.

Périmètre du projet présenté

Le produit livré est un **outil d'aide à la décision expérimentale**. Le logiciel ne détermine pas directement le meilleur rendement, le meilleur tag ou la meilleure température ; il organise des comparaisons qui restent à valider sur paillasse.

Un glossaire plus complet est fourni en annexe A; la synthèse précédente a volontairement évité les sigles techniques.

Sommaire et correspondance avec le template

Parties évaluées	Pages du rapport
1. Besoins et contexte · 2. Audit de la solution data	4 à 7
3. Choix de solution · 4. Stratégie et méthode	8 à 13
5. Contrôle et suivi · 6. Conclusion	14 à 16
7. Annexes, résultats détaillés et sources	17 à 20

1. CONTEXTE ET ANALYSE DES BESOINS

1.1 Organisation et maturité data & ML

Organisation et secteur

Il s'agit d'un **projet individuel** réalisé pour la formation Data Scientist – Machine Learning, appliqué à la R&D en biochimie, biotechnologie et production de protéines recombinantes. La « structure » du projet comporte une personne assurant cadrage, préparation des données, modélisation, développement et documentation. Il n'existe ni client industriel commanditaire ni effectif de laboratoire affecté au projet. Les rôles biologiste, responsable de plateforme et qualité correspondent à des interlocuteurs cibles pour un éventuel pilote, pas à une équipe officiellement engagée.

Maturité de départ : diagnostic SWOT ciblé

Axe	Forces observées	Faiblesses / vigilance
Métier / données	Expérience pratique de production, purification, contrôle qualité	Données publiques hétérogènes ; conditions de production incomplètes
Data & ML	Première chaîne supervisée, métriques et tests	Sensibilité à l'homologie ; faible preuve externe
MLOps	Git, FastAPI, Docker, CI/CD, suivi et optimisation explorés	Écart entre prototypes techniques et usage scientifique réel
Adoption	Problème concret, profils d'utilisateurs identifiables	Pas de mesure d'usage ou de gains expérimentaux
Sécurité	Reproductibilité et séparation des artefacts privés	Recherche externe de séquences à encadrer

Enjeux stratégiques liés à la donnée

La maturité recherchée n'est pas une production industrielle autonome, mais un **démonstrateur opérationnel et contrôlable** : saisie facile, provenance des données, seuil explicite, recommandations compréhensibles, code traçable et limites annoncées. Le passage à un service laboratoire exigerait un pilote prospectif et des règles de confidentialité.

1.2 Besoin métier, utilisateurs et critères

Trois observations métier qui ont guidé le cadrage

- La sélection s'effectue en comparant domaines, bornes de constructions, mutations et tags selon l'objectif expérimental.
- Des difficultés reviennent : précipitation, agrégation, mauvais repliement, fraction soluble insuffisante ou activité perdue.
- Un cycle infructueux engage préparation, expression, lyse, analyse et parfois purification; les coûts varient selon la cible et l'échelle.

Parties prenantes et exigences prioritaires

Utilisateur cible	Besoin	Critère de réussite
Biochimiste / ingénieur de recherche	Décider quels essais lancer	Score lisible et propositions motivées
Responsable de plateforme	Comparer coût des options	Suivi des coûts et essais évités
Chef de projet Data/ML	Comparer, reproduire, déployer	Versions et tests de non-régression
Qualité / SI	Contrôler les données et services tiers	Traçabilité, contrôle d'accès et évaluation des risques

Recueil du besoin : capitalisation de l'expérience professionnelle et revue des étapes de production; les entretiens utilisateurs et ateliers multi-équipes constituent un travail futur. La priorisation est issue du cadrage individuel, pas d'un consensus client.

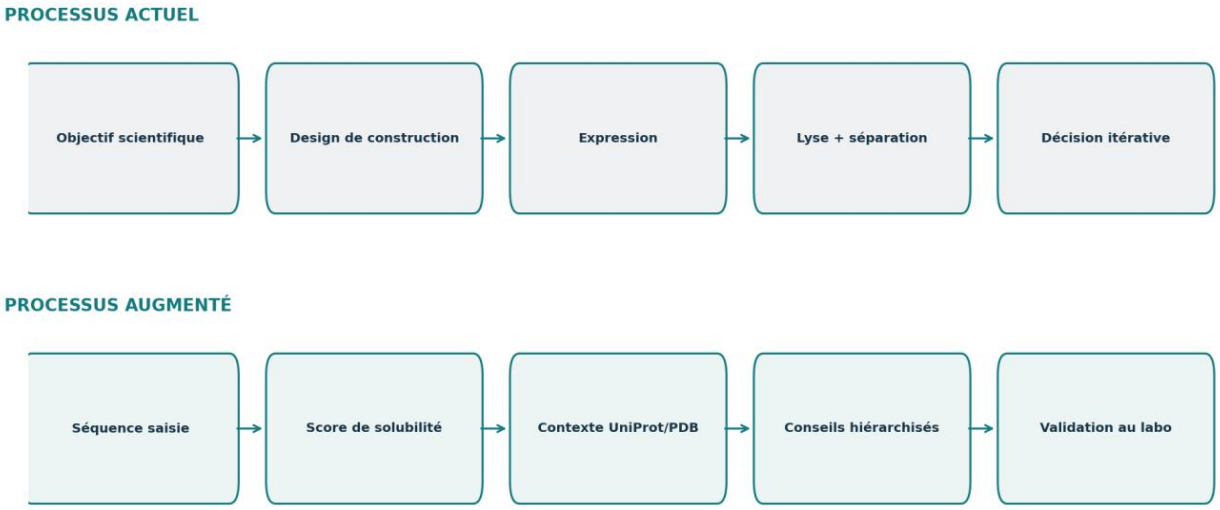
Exigences fonctionnelles retenues

- Essentielles : prédire depuis une séquence brute, expliciter la longueur analysée, figer les paramètres et donner un résultat vérifiable.
- Importantes : identifier la protéine avec provenance, proposer des constructions hiérarchisées, produire une fiche PDF.
- Hors périmètre : garantir un tag, un rendement, un hôte ou une température optimaux sans données dédiées.

2. AUDIT DE LA SOLUTION DATA

2.1 Processus actuel et flux de données

Le processus habituel est itératif : le chercheur définit une cible, conçoit plusieurs constructions, réalise des essais, mesure les fractions solubles et insolubles et recommence si nécessaire. L'outil ajoute une étape d'aide au choix **en amont du premier essai**, sans supprimer la validation expérimentale.



Flux de données mis en place

Entrée / étape	Transformation	Sortie / contrôle
Séquence brute	Vérification des 20 AA standards, longueur	Entrée admissible ; erreurs explicites
Données étiquetées	Alignement identifiants et contrôle d'homologie	Partitions de développement séparées
Modèle de séquence + Bio13	Encodage et classement par le modèle	Score et longueur réellement analysée
Bases publiques	Recherche de similarité PDB/UniProt	Annotation avec provenance, si fiable
Règles métier	Hiérarchisation d'essais et contrôles	Plan expérimental indicatif + PDF
Versions du code	Tests GitHub + gestion du checkpoint privé	Reproductibilité et traçabilité

Risques associés au processus

La séquence peut être confidentielle ; une recherche externe demande une politique d'autorisation. Les données de solubilité publiques ne décrivent pas toujours le même protocole d'expression, et deux protéines homologues peuvent fausser l'évaluation si elles passent d'un jeu à l'autre.

2. AUDIT DE LA SOLUTION DATA

2.2 Données, partitions et écarts

Un jeu de données, cinq usages distincts

Partition	Nombre	À quoi sert-elle ?
Fit	46 270	Apprendre les paramètres du modèle.
Tune	4 052	Comparer les variantes et retenir une architecture.
Calibration	4 052	Réserve pour ajuster l'interprétation probabiliste ; non utilisée dans la campagne comparative décrite.
Threshold	4 052	Choisir la règle de décision économique; scindée en deux moitiés dans la finalisation.
Holdout	4 052	Jeu mis de côté ; pas un test indépendant disponible pour la version fine-tunée.

Pourquoi séparer ? Si l'on règle puis évalue plusieurs fois sur les mêmes protéines, on finit par surajuster les choix au jeu de test. Les groupes de séquences apparentées sont contrôlés autant que possible, notamment avec l'outil de recherche d'homologie MMseqs2.

Écarts constatés lors de l'audit

Point audité	Risque pour l'objectif métier	Réponse projet
Labels et protocoles	Une annotation « soluble » peut dépendre de l'hôte et du protocole	Documenter la portée du score
Séquences homologues	Trop bonne performance artificielle	Contrôle des similarités entre groupes
Confusion score / rendement	Décisions trop confiantes	Préciser qu'un score ne mesure pas le rendement
Troncature longue	Perte de domaines utiles	Politique de longueur documentée
Mesure métier absente	ROI invérifiable	Prévoir un pilote contrôlé

3. IDENTIFICATION D'UNE SOLUTION CIBLE

3.1 Cas d'usage : méthode de priorisation

Les cas d'usage ont été identifiés à partir des points de décision du processus décrit en section 2.1, puis notés sur quatre critères : **impact métier 40 %**, **faisabilité 30 %**, **disponibilité des données 20 %** et **maîtrise du risque 10 %**. Chaque note va de 1 (faible) à 5 (fort). Ce scoring est une proposition de cadrage, non le résultat d'un comité client.

Cas d'usage	Impact	Fais.	Données	Risque	Score /5	Rang
Classement des séquences	5	4	5	3	4,5	1
Identification de la cible	4	4	4	3	3,9	2
Plan d'essais et contrôles	4	3	2	2	3,1	3
Optimisation tag/hôte/induction	5	1	1	1	2,6	4

Arbitrage produit

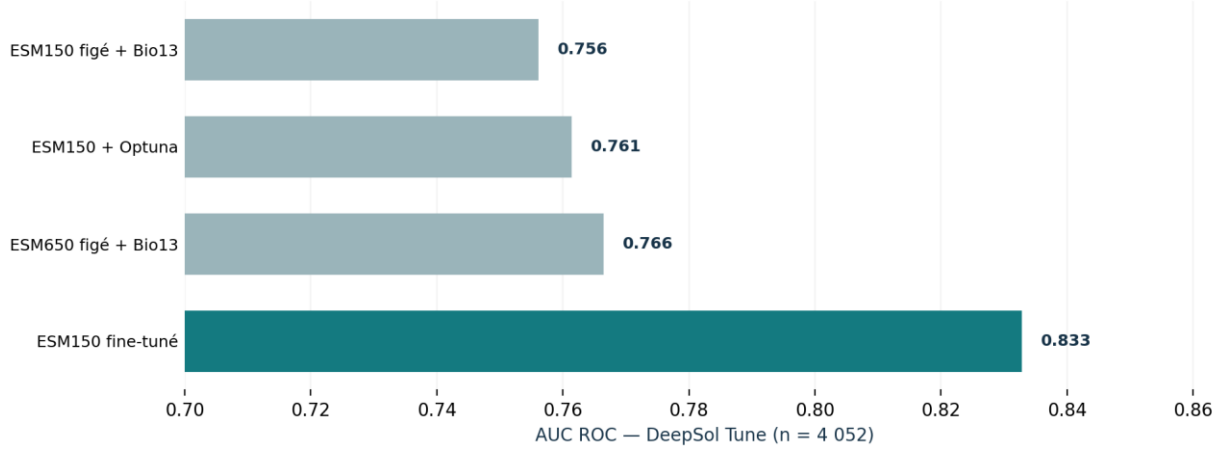
- **Priorité 1:** classement ML de séquences avec résultats lisibles.
- **Priorité 2:** identification automatique, avec un seuil de confiance et des sources.
- **Priorité 3:** conseils expérimentaux fondés sur des règles expertes, avec conditions et contre-indications.
- **Reporté :** optimisation chiffrée de tags, température ou hôte, faute de données d'entraînement adaptées.

Le produit livré reflète cet arbitrage: on ne présente pas le conseil d'expression comme une deuxième prédiction validée, mais comme une orientation pour construire un plan de comparaison.

3. IDENTIFICATION D'UNE SOLUTION CIBLE

3.2 Comparaison des options techniques

L'arbitrage a considéré **pouvoir discriminant**, **coût de calcul**, **simplicité de déploiement** et **pertinence pour la séquence protéique**. La première solution LightGBM était peu coûteuse et industrialisable, mais limitée en performance. Les représentations de protéines pré-entraînées ont été testées ensuite, puis adaptées à la tâche.



Option	Performance sur Tune	Choix
ESM-2 150M figé + 13 critères Bio13	≈ 0,76	Alternative légère
Même modèle + optimisation des paramètres	≈ 0,76	Gain insuffisant
ESM-2 650M figé	≈ 0,77	Calcul plus coûteux
ESM-2 150M partiellement réentraîné	≈ 0,83	Retenu pour le démonstrateur

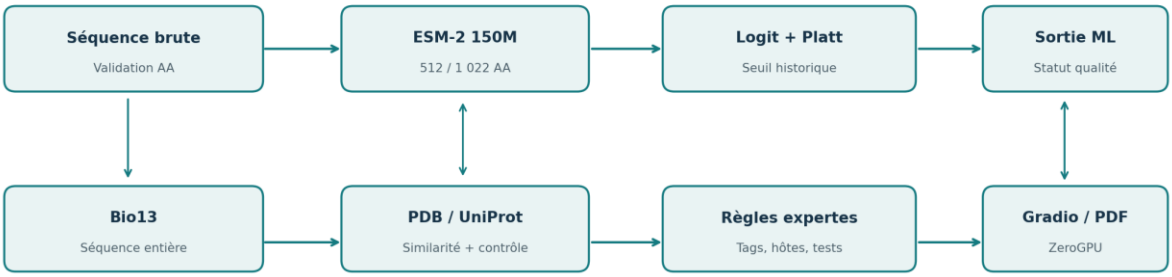
L'indicateur représente la capacité à classer correctement une paire de protéines soluble/insoluble. Ces scores sont issus d'un **jeu de mise au point commun** (4 052 protéines), pas d'un essai clinique ou d'une validation industrielle indépendante.

Ce que nous ne pouvons pas conclure

L'amélioration ne peut pas être attribuée à un seul réglage : modèle de classification, fine-tuning et pipeline ont évolué ensemble. Le meilleur score décrit le prototype sélectionné ; il ne mesure pas à lui seul la valeur économique en laboratoire.

3. IDENTIFICATION D'UNE SOLUTION CIBLE

3.3 Architecture retenue et contraintes



Le produit sépare **trois fonctions** : 1) une prédiction issue de l'entraînement ; 2) une recherche PDB/UniProt fournissant un contexte biologique si la concordance est suffisante ; 3) un moteur de règles qui classe les constructions et contrôles possibles. Cette séparation évite d'affirmer qu'un tag conseillé est prédit par le réseau neuronal.

Politique de longueur conservée

Longueur de la protéine	Information exploitée	Affichage
Jusqu'à 512 AA	Toute la séquence	Mode de référence
De 513 à 1 022 AA	Toute la séquence	Mode expérimental, score non recalibré pour ce mode
Au-delà de 1 022 AA	512 premiers AA	Troncature signalée

Le test de développement montre un intérêt particulier pour les séquences de 513 à 1 022 AA (**360 exemples : AUC ≈ 0,81 → 0,85**). Le gain global est faible, car la majorité des protéines sont plus courtes. Ce constat motive une extension prudente et non un changement silencieux du modèle.

Livraison

Interface web Gradio sur Hugging Face Spaces / ZeroGPU, code documenté sur GitHub, poids privés dans un dépôt séparé et tests automatiques sans GPU. La robustesse en conditions de charge et l'usage de séquences propriétaires restent hors périmètre.

4. APPUI STRATÉGIQUE ET MÉTHODOLOGIQUE

4.1 Méthode, pivot et gouvernance

Gestion de projet : démarche itérative inspirée de CRISP-DM

Le projet a suivi des boucles courtes : **cadrer le besoin**, auditer les données, construire une référence, comparer, analyser les erreurs, puis améliorer la livraison. Les choix sont appuyés par des expériences, des commits et un journal de modifications. Cette méthode permet de réorienter l'effort lorsque le besoin réel apparaît mieux défini.

Le changement de cap est une décision de pilotage

Phase 1 — priorité industrialisation. Le projet initial mettait l'accent sur LightGBM, FastAPI, Docker, intégration continue, tests et surveillance. Il a permis de démontrer une chaîne MLOps complète, mais le produit restait centré sur une prédiction peu contextualisée pour le biologiste.

Phase 2 — priorité usage et qualité de prédiction. Les essais de modèles protéiques ont montré un gain sur le jeu de développement. J'ai donc retenu ESM-2 fine-tuné, remplacé l'interface de démonstration par Gradio et ajouté les annotations biologiques et les règles de conception.

Ce qui a été conservé : Git, versions, tests, séparation des artefacts, logique de suivi et exigences de reproductibilité. **Ce qui a été mis de côté :** l'API Docker/ONNX comme produit principal ; son code est archivé, non perdu. Ce pivot privilégie la qualité de la démonstration métier sans effacer les compétences MLOps acquises.

Organisation de la décision

La porteuse du projet cumule les responsabilités métier et technique dans ce POC individuel. Pour un pilote, le biologiste valide les cas d'usage et les résultats, le responsable de plateforme arbitre le budget, la Data Scientist gère les évaluations, et le référent SI/qualité contrôle les accès et la confidentialité.

4. APPUI STRATÉGIQUE ET MÉTHODOLOGIQUE

4.1 (suite) — Roadmap : dates, jalons et responsabilités



Historique disponible : prévu et réalisé

Jalon	Référence de planification	Réalisé / preuve	Écart
Première chaîne MLOps	Objectif initial: API et tests	03–05/07/2026: commits FastAPI, Docker, CI	Jalon atteint ; durée initiale non consignée
Cycle initial V2/V3	Référence d'effort estimée : ≈ 15 j-personne	03–24/07: 22 jours calendaires entre premiers et derniers commits	Non calculable: jours-personne ≠ jours calendaires
Campagne ESM-2	Prévision datée d'origine non conservée	Octobre : comparaisons et fine-tuning documentés	Non calculable
Démonstrateur et dépôt stabilisés	Décision d'arrêt de version	22–25/10 : Space, tests, version GitHub	Livré au 25/10

Les dates réelles proviennent de l'historique des commits et des sorties d'expériences. **Aucune planification contractuelle antérieure chiffrée n'a été retrouvée** : inventer un retard précis serait trompeur. Le tableau confronte donc les objectifs de départ aux dates effectivement documentées.

Plan prospective proposé pour une validation métier — non réalisé

Phase proposée	Fenêtre indicative	Responsable cible	Jalon de sortie
Définir cohorte et protocoles	Semaine 1	Biologiste + Data	Critères d'inclusion signés
Préparer et auditer les données	Semaines 2–3	Data + qualité	Jeu externe gelé
Criblage comparatif en laboratoire	Semaines 4–6	Biologiste / plateforme	Résultats soluble/insoluble et activité
Bilan coût, délai et adoption	Semaine 7	Chef de projet + responsable	Décision go / no-go

4.2 Arbitrages financiers et risques

Trois scénarios de financement — estimations non engagées

Scénario	Périmètre	Budget estimatif
A — qualité de données	Qualité, homologie, protocole et traçabilité	7 000 €
B — amélioration ML	A + nouvelles évaluations et calibration	12 500 €
C — pilote biologique	B + essai prospectif et mesure de valeur	23 000 €

Illustration du retour sur investissement : avec un cycle expérimental évité valorisé à 2 000 € (hypothèse pédagogique), A demand 4 cycles évités, B en demande 7 et C en demande 12 pour couvrir leur budget. Aucun cycle réellement évité n'a encore été mesuré.

La fonction de coût : un arbitrage métier discutable et explicite

Le seuil actuellement figé utilise **1 200 € par faux négatif** (une protéine réellement soluble écartée) et **600 € par faux positif** (un essai inutile sur une insoluble). Il favorise donc la récupération de protéines potentiellement intéressantes, même au prix d'essais supplémentaires. Ce choix n'est cohérent que si **la valeur d'une bonne cible manquée dépasse le coût d'un essai évitable**.

Si l'objectif prioritaire devient strictement la réduction des essais inutiles, cette pondération doit être discutée, voire inversée, **avant** un nouveau réglage du seuil sur des données distinctes. Le prototype ne prétend pas démontrer que les valeurs 1 200 € et 600 € sont les vrais coûts d'un laboratoire.

Risques majeurs et réponses

Risque	Impact	Parade
Fuite de données par homologie	Score artificiellement optimiste	Groupes et recherche de similarité
Labels dépendants des protocoles	Décisions peu transférables	Documenter les conditions de référence
Séquence propriétaire transmise à un tiers	Confidentialité	Désactiver recherche externe sans autorisation
Conseils pris comme prédictions garanties	Essais inadaptés	Règles expliquées + validation scientifique
Absence de suivi économique	ROI non prouvable	Mesure prévue par cycle d'essai

Indicateurs de succès (KPI business et techniques)

Catégorie	KPI à suivre	Preuve / état
Métier	Essais évités ; fraction soluble ; heures et € par construction	Pilote avec lot témoin ; non mesuré
Modèle	AUC ≈ 0,83 sur Tune ; rappel ≈ 0,86 au choix du seuil	Mesures de développement
Service	Calibration, dérive, latence P95, disponibilité	À évaluer en exploitation

Responsabilité scientifique, confidentialité et conformité

La décision d'engager un essai reste humaine : aucun choix de production ne peut reposer sur le seul score. En pilote, toute transmission de séquences confidentielles à PDB/UniProt requiert une autorisation ; les licences, conditions d'usage et annotations externes doivent être vérifiées. Un biologiste confirme les recommandations et les résultats expérimentaux.

5. CONTRÔLE ET SUIVI

5.1 Tableau de bord : délais, coûts, livrables, qualité

Le tableau de bord distingue une **situation observée** d'un **objectif à piloter**. Une case « non relevé » signifie qu'aucune mesure historique fiable n'est disponible, et non que le coût ou le retard est nul.

Dimension	Prévu / objectif	Réalisé ou état constaté	Écart / décision
Délais – cycle MLOps	Effort estimatif : 15 j-personne	03–24 juillet : 22 j calendaires	Non comparable ; temps passé non relevé
Délais – démonstrateur	Version stabilisée en octobre	application livrée, GitHub et CI au 25/10	Livrable atteint
Coûts – projet réalisé	Budget de référence initial non documenté	Dépenses effectives: non relevées	Mettre en place suivi de factures/temps
Coûts – pilote futur	Scénarios : 7 000 / 12 500 / 23 000 €	Aucun budget engagé	Soumettre arbitrage
Livrables	Interface, documentation, tests	Application en ligne, PDF, dépôt et Actions	Terminé pour démonstrateur
Qualité data	Partitions distinctes, homologie contrôlée	62 478 séquences partitionnées	Contrôle exhaustif non garanti
Performance ML	Meilleur discriminant sur Tune	AUC ≈ 0,83 ; PR-AUC ≈ 0,79	Données externes nécessaires
Coût d'erreur simulé	Minimiser coût FN/FP avec rappel minimal	387 600 € sur sous-ensemble de choix de seuil	Mesure de réglage, pas économie constatée

Lecture des indicateurs : coûts, temps et livrables

Délai réel : le temps écoulé entre deux commits n'est pas une mesure de jours travaillés. **Coût réel :** sans timesheet, factures et coût d'infrastructure, on ne peut pas déclarer un « réalisé » monétaire. **Performance :** un score technique ne remplace pas la mesure d'essais économisés.

Ce tableau évite de mélanger une enveloppe budgétaire prospective, un coût hypothétique d'erreur de classification et une dépense effectivement supportée par le projet.

5. CONTRÔLE ET SUIVI

5.2 Outils, reporting et qualité de livraison

Outils effectivement utilisés

Outil	Utilité	Preuve / limite
Git / GitHub	Historique, branches, documentation	Commits datés, version principale stabilisée
GitHub Actions	Exécuter les tests de non-régression	Derniers tests sans GPU réussis
Google Colab / GPU	Entraîner et comparer les modèles	Sorties de campagnes sauvegardées
Hugging Face Spaces	Démonstration web	Gradio accessible; latence à caractériser
MMseqs2	Chercher des séquences apparentées	Audit approché, non exhaustif
PDB / UniProt	Mettre le score dans son contexte	Correspondance à contrôler

Cadence de suivi recommandée en pilote

- À chaque import de données : contrôle qualité et recherche de doublons/homologies.
- À chaque commit : tests automatiques et vérification des secrets.
- Chaque semaine : avancement des jalons, dépenses engagées, heures consommées et incidents.
- Après chaque campagne : fraction soluble, activité, essai évité ou non, coût complet et avis utilisateur.

Facteurs clés de succès et points de vigilance

Porte	Condition de passage
Scientifique	Résultats reproduits sur protéines inédites et protocoles comparables
Métier	Réduction prouvée des cycles inutiles sans perte excessive de bonnes cibles
Exploitation	Confidentialité, disponibilité et maintenance documentées

6. CONCLUSION ET RECOMMANDATIONS

Un démonstrateur terminé, un pilote à décider

Le projet a évolué d'un premier pipeline de classification et d'industrialisation vers une application de recherche plus directement exploitable : l'utilisateur saisit une séquence, voit une prédiction, obtient un contexte biologique lorsque disponible et prépare un plan d'essais comparatifs.

L'approche retenue est la meilleure observée sur les comparaisons de développement menées, avec un indice de discrimination d'environ 0,83. Les tests automatiques et la livraison web montrent que l'application est reproductible en tant que démonstrateur. L'évaluation externe du modèle fine-tuné et le gain économique réel constituent encore les preuves à produire.

Décisions prises pendant la conduite du projet

- Abandonner l'ajout brut de nouvelles protéines externes lorsque la performance baisse sur le jeu comparatif.
- Préférer un modèle protéique partiellement adapté à une architecture figée plus lourde et plus coûteuse à exécuter.
- Conserver les briques MLOps acquises dans l'historique, tout en recentrant le produit sur une interface métier.
- Présenter les recommandations de tags/hôtes comme des règles métier explicables et non comme une optimisation apprise.
- Figer le produit livré afin de stopper les ajustements successifs sur les mêmes données.

Prochaine décision proposée

Autoriser, ou non, un pilote prospectif avec une équipe de production de protéines. Le cahier des charges doit définir les coûts des deux types d'erreurs, une cohorte nouvelle, les indicateurs de rendement soluble et d'activité, ainsi qu'un journal des délais et des dépenses. **La décision go/no-go reposera sur ces résultats**, pas sur la seule métrique du prototype.

7. ANNEXES

Annexe A — glossaire opérationnel

Terme	Définition pour un lecteur non spécialiste
AA	Acide aminé : élément d'une séquence protéique.
AUC ROC	Mesure entre 0 et 1 de la qualité du classement ; 0,5 équivaut au hasard.
PR-AUC	Mesure de la qualité du classement de la classe soluble, sensible à sa fréquence.
Bio13	Treize caractéristiques biochimiques calculées sur la séquence.
Calibration / Platt	Méthode permettant de relier les scores bruts à des fréquences observées.
CI/CD	Tests et opérations automatiques autour des changements de code.
ESM-2 150M	Modèle de langage pour protéines comportant environ 150 millions de paramètres.
Fine-tuning	Adaptation d'une partie d'un modèle pré-entraîné à une tâche précise.
FN / FP	FN : soluble rejetée ; FP : insoluble acceptée.
Gradio / ZeroGPU	Interface web / dispositif d'accès à un GPU à la demande.
Homologie	Parenté entre protéines susceptible de rendre les échantillons dépendants.
LightGBM	Méthode de classification sur données tabulaires.
MMseqs2	Logiciel de recherche rapide de similarités entre séquences.
PDB / UniProt	Bases publiques d'informations structurales et fonctionnelles sur les protéines.
Tag / hôte	Étiquette fusionnée à la protéine / organisme ou cellule servant à la produire.
Holdout / Tune	Jeu conservé pour tester / jeu utilisé pour choisir les modèles.
MLOps	Pratiques pour versionner, tester, livrer et surveiller des modèles ML.

7. ANNEXES

Annexe B — résultats chiffrés et choix écartés

Comparaison des modèles — sur le jeu Tune (n = 4 052)

Variante explorée	AUC exacte	PR-AUC exacte
ESM-2 35M figé	0,7297	0,6587
ESM-2 35M + Bio13	0,7383	0,6735
ESM-2 150M figé	0,7511	0,6854
ESM-2 150M + Bio13	0,7562	0,6864
ESM-2 150M + Optuna	0,761432	0,693242
ESM-2 650M figé + Bio13	0,766446	0,701039
ESM-2 150M fine-tuné + Bio13	0,832857	0,786022

Apports complémentaires non retenus

UEsolDS : 70 029 séquences valides uniques, puis exclusion de 10 994 doublons exacts et de 25 386 homologues identifiés ; 33 649 supplémentaires retenues. L'AUC Tune du modèle figé + Bio13 a baissé de 0,756177 à 0,733012 après augmentation du Fit à 79 919. Cette baisse ne prouve pas à elle seule sa cause.

Descripteurs supplémentaires : meilleure variation Tune observée +0,0014 avec la longueur brute, trop faible pour justifier un changement.

Troncature : chiffres de Tune

Population	N	AUC 512 AA	AUC 1 022 AA
Total	4 052	0,832857	0,834727
Jusqu'à 512 AA	3 672	0,834522	0,834522
513 à 1 022 AA	360	0,813852	0,848630

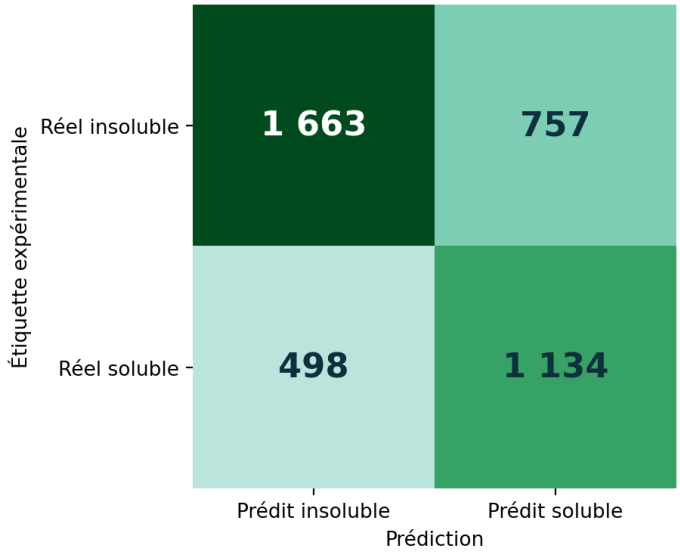
Les 20 protéines de plus de 1 022 AA ne sont pas représentées graphiquement : échantillon trop petit pour soutenir une interprétation stable.

7. ANNEXES

Annexe C — erreurs de classification et seuil économique

Matrice de confusion disponible : ancienne variante ESM-2 figée

L'exemple ci-dessous est une mesure réelle d'une ancienne variante ESM-2 150M figée avec Bio13, sur son holdout historique de 4 052 protéines. Ce n'est pas une matrice de confusion de la version fine-tunée. La comparer directement à la version livrée serait incorrect.



Erreur / résultat historique	Effectif	Sens métier
Vrais négatifs	1 663	Insolubles correctement écartées
Faux positifs	757	Insolubles jugées solubles → essais inutiles possibles
Faux négatifs	498	Solubles écartées → occasions manquées
Vrais positifs	1 134	Solubles correctement retenues

Sur cette ancienne variante, le coût théorique selon les mêmes pondérations atteint 1 051 800 €, soit 757 × 600 € + 498 × 1 200 €. Cette valeur ne mesure aucun coût réel de laboratoire et ne doit pas être attribuée à la version livrée.

Seuil économique du modèle fine-tuné : protocole de finalisation

Dans la finalisation documentée, la partition Threshold a été séparée en 2 026 séquences pour ajuster la correspondance entre scores et probabilités, puis 2 026 pour choisir un seuil sous contrainte de rappel minimum de 40 %. Le seuil fixé était **0,296491** et le rappel atteint **0,8575** sur le sous-ensemble utilisé pour la sélection ; le coût simulé y était **387 600 €**. Ce dernier chiffre est un coût de réglage, non un test indépendant.

Le jeu Tune a déjà été utilisé pour choisir les architectures. Il n'existe pas, dans les éléments disponibles, de matrice de confusion finale indépendante du fine-tuning à reproduire sans refaire une évaluation nouvelle.

7. ANNEXES

Annexe D — indicateurs, traçabilité et sources

Fiche de suivi à compléter pendant un pilote

Date / lot	Prévu	Réalisé	Écart / action
Début/fin des essais	Date, responsable, objectif	Date et durée constatées	Retard en jours
Temps de travail	Heures budgétées	Heures déclarées	Écart de charge
Consommables et GPU	Budget autorisé	Factures / coûts enregistrés	Écart € et %
Construits/expressés	Nombre d'essais prévus	Nombre et fractions solubles	Efficacité réelle
Activité et pureté	Critères fixés	Résultats biologiques	Décision expérimentale

Livrables consultables

Application publiée : https://huggingface.co/spaces/fatimaadda2878/protein-solubility-esm150-ft

Code source et tests : https://github.com/fatimaadda2878/protein-solubility-api

Documentation technique : README, docs/ARCHITECTURE.md, docs/RESULTATS_ET_LIMITES.md et journal CHANGELOG.

Références techniques et pédagogiques

- Template fourni : Rapport de conduite de projet Data & ML, sections 1 à 7.
- Khurana et al. (2018), DeepSol: a deep learning framework for sequence-based protein solubility prediction. Bioinformatics 34, 2605–2613.
- Lin et al. (2023), Evolutionary-scale prediction of atomic-level protein structure with a language model. Science 379, 1123–1130.
- RCSB PDB : https://www.rcsb.org/docs/programmatic-access/web-apis-overview
- UniProt API : https://www.uniprot.org/help/api
- Hugging Face Spaces : https://huggingface.co/docs/hub/spaces
- Artefacts du projet : sorties Colab (campagne finale, audit UESolDS, finalisation du seuil et test 512/1 022 AA).

Les chiffres complets sont conservés ici pour audit ; le corps du rapport emploie des arrondis adaptés à la décision.